UNIVERSIDAD PANAMERICANA

CIUDAD UP · FACULTAD DE CIENCIAS EMPRESARIALES

Tarea — Series de Tiempo para Finanzas

ARIMA(p, d, q) · SARIMA · SARIMAX · Pronóstico

Solución — Ejercicios 1.1 a 3.3

Dr. César Galindo

Verano 2026

Procesos estacionarios y fundamentos

Ejercicio 1.1 — Estacionariedad, ACF y PACF

(a)

Solución:

Estacionariedad débil (de covarianza). El proceso $\{Y_t\}_{t\in\mathbb{Z}}$ es *débilmente estacionario* si:

(i) $\mathbb{E}[Y_t] = \mu$ para todo t (media constante);

(ii) $\mathrm{Cov}(Y_t, Y_{t-k}) = \gamma(k)$ depende únicamente del rezago k, no de t.

Estacionariedad estricta. La distribución conjunta de $(Y_{t_1}, \ldots, Y_{t_m})$ es idéntica a la de $(Y_{t_1+h}, \ldots, Y_{t_m+h})$ para todo h y toda elección de índices.

Ejemplo. Sea $Y_t = \cos(t)\, U$ donde $U \sim \mathcal{N}(0,1)$. Entonces

$$\mathbb{E}[Y_t] = \cos(t)\,\mathbb{E}[U] = 0, \qquad \mathrm{Cov}(Y_t, Y_{t-k}) = \cos(t)\cos(t-k)\,\mathbb{E}[U^2] = \cos(t)\cos(t-k).$$

La covarianza depende de t, así que *no* es débilmente estacionario.

Un ejemplo más sutil de proceso débilmente estacionario que *no* es estrictamente estacionario: sea ε_t i.i.d. con $\mathbb{E}[\varepsilon_t] = 0$, $\mathrm{Var}(\varepsilon_t) = \sigma^2$, pero con distribución que cambia en el tiempo (e.g. mezcla de normales con misma media y varianza). La función de autocovarianza cumple $\gamma(k) = 0$ para $k \neq 0$, pero la distribución conjunta cambia con el tiempo.

(b)

Solución:

Sea $\gamma(k) = \mathrm{Cov}(Y_t, Y_{t-k})$.

Demostración de $|\rho(k)| \leq 1$. Por la desigualdad de Cauchy-Schwarz:

$$|\,\mathrm{Cov}(Y_t, Y_{t-k})| \leq \sqrt{\mathrm{Var}(Y_t)}\,\sqrt{\mathrm{Var}(Y_{t-k})} = \gamma(0),$$

donde la última igualdad usa $\mathrm{Var}(Y_t) = \mathrm{Var}(Y_{t-k}) = \gamma(0)$ (estacionariedad). Por lo tanto:

$$|\rho(k)| = \frac{|\gamma(k)|}{\gamma(0)} \leq 1. \qquad \checkmark$$

Demostración de $\rho(k) = \rho(-k)$. La covarianza es simétrica:

$$\gamma(-k) = \mathrm{Cov}(Y_t, Y_{t+k}) = \mathrm{Cov}(Y_{t+k}, Y_t) = \gamma(k),$$

donde la segunda igualdad usa la simetría del operador de covarianza, y la tercera usa estacionariedad (rezago k). Dividiendo por $\gamma(0)$:

$$\rho(-k) = \frac{\gamma(-k)}{\gamma(0)} = \frac{\gamma(k)}{\gamma(0)} = \rho(k). \qquad \checkmark$$

(c)

Solución:

Sea $Y_t = 0.6\,Y_{t-1} + \varepsilon_t$, $\varepsilon_t \sim \mathrm{WN}(0, \sigma^2)$, con $|\phi| = 0.6 < 1$, proceso estacionario.
Varianza. Aplicando varianza a ambos lados y usando independencia de ε_t con Y_{t-1}:

$$\gamma(0) = 0.36\,\gamma(0) + \sigma^2 \implies \gamma(0) = \frac{\sigma^2}{1 - 0.36} = \frac{\sigma^2}{0.64}.$$

Covarianza con rezago 1. Multiplicando la ecuación del AR(1) por Y_{t-1} y tomando esperanza:

$$\gamma(1) = \mathrm{Cov}(Y_t, Y_{t-1}) = 0.6\ \mathrm{Cov}(Y_{t-1}, Y_{t-1}) + \mathrm{Cov}(\varepsilon_t, Y_{t-1}) = 0.6\,\gamma(0).$$

Función de autocorrelación. Por las ecuaciones de Yule-Walker para el AR(1):

$$\gamma(k) = 0.6\,\gamma(k-1), \quad k \geq 1.$$

Resolviendo la recurrencia con condición inicial $\gamma(0)$:

$$\gamma(k) = 0.6^k\,\gamma(0), \quad k \geq 0.$$

Por lo tanto:

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)} = 0.6^k, \quad k \geq 0. \qquad \checkmark$$

(d)

Solución:

AR(1) con $\phi > 0$: La ACF decae exponencialmente como $\rho(k) = \phi^k \to 0$. La PACF se corta abruptamente en el rezago 1 (i.e., $\alpha(1) = \phi$ y $\alpha(k) \approx 0$ para $k \geq 2$).
MA(1) con $\theta > 0$: La ACF se corta en el rezago 1: $\rho(1) = \theta/(1+\theta^2)$ y $\rho(k) = 0$ para $k \geq 2$. La PACF decae exponencialmente (en valor absoluto).
Ruido blanco: ACF ≈ 0 y PACF ≈ 0 para todo $k \geq 1$ (todos los valores dentro de la banda $\pm 1.96/\sqrt{T}$).
¿Por qué sirven para identificar el orden? La PACF de un AR(p) se anula exactamente a partir del rezago $p+1$, por lo que el orden p se lee directamente como el último rezago significativo. Análogamente, la ACF de un MA(q) se anula a partir del rezago $q+1$. Estos cortes abruptos son las "firmas" que permiten distinguir el tipo y orden del proceso.

Ejercicio 1.2 — Procesos AR, MA y ARMA

(a)

Solución:

El AR(2) es $Y_t = 1.2\,Y_{t-1} - 0.32\,Y_{t-2} + \varepsilon_t$. El polinomio AR es:

$$\Phi(z) = 1 - 1.2z + 0.32z^2.$$

Raíces de $\Phi(z) = 0$:

$$z = \frac{1.2 \pm \sqrt{1.44 - 4(0.32)}}{2(0.32)} = \frac{1.2 \pm \sqrt{1.44 - 1.28}}{0.64} = \frac{1.2 \pm \sqrt{0.16}}{0.64} = \frac{1.2 \pm 0.4}{0.64}.$$

$$z_1 = \frac{1.6}{0.64} = 2.5, \qquad z_2 = \frac{0.8}{0.64} = 1.25.$$

Ambas raíces satisfacen $|z_i| > 1$, i.e., están fuera del círculo unitario. **Conclusión:** el proceso AR(2) es **estacionario**.

(b)

Solución:

El MA(2) es $Y_t = \varepsilon_t + 0.5\,\varepsilon_{t-1} - 0.3\,\varepsilon_{t-2}$.
Varianza:

$$\mathrm{Var}(Y_t) = (1 + 0.5^2 + 0.3^2)\,\sigma^2 = (1 + 0.25 + 0.09)\,\sigma^2 = 1.34\,\sigma^2.$$

Covarianza rezago 1:

$$\begin{aligned}\gamma(1) &= \mathrm{Cov}(Y_t, Y_{t-1}) = \mathrm{Cov}(\varepsilon_t + 0.5\varepsilon_{t-1} - 0.3\varepsilon_{t-2},\, \varepsilon_{t-1} + 0.5\varepsilon_{t-2} - 0.3\varepsilon_{t-3}) \\ &= 0.5\,\sigma^2 + 0.5(-0.3)\,\sigma^2 = (0.5 - 0.15)\,\sigma^2 = 0.35\,\sigma^2.\end{aligned}$$

Covarianza rezago 2:

$$\gamma(2) = \mathrm{Cov}(\varepsilon_t + 0.5\varepsilon_{t-1} - 0.3\varepsilon_{t-2},\, \varepsilon_{t-2} + 0.5\varepsilon_{t-3} - 0.3\varepsilon_{t-4}) = -0.3\,\sigma^2.$$

Covarianza rezago $k \geq 3$: No hay términos de ε en común, por lo que $\gamma(k) = 0$ para $k \geq 3$.

(c)

Solución:

Un MA(q) es invertible si las raíces del polinomio de medias móviles $\Theta(z) = 1 + \theta_1 z + \cdots + \theta_q z^q$ están *fuera* del círculo unitario, es decir, si $|\tilde{z}_j| > 1$ para toda raíz $\tilde{z}_j$ de $\Theta(z) = 0$.

Importancia para el pronóstico: La invertibilidad garantiza que el proceso MA(q) admite una representación AR(∞) convergente:

$$Y_t = -\sum_{j=1}^{\infty} \pi_j Y_{t-j} + \varepsilon_t,$$

con $\sum |\pi_j| < \infty$. Esto significa que ε_t puede escribirse como función de los valores pasados $\{Y_{t-j}\}_{j\geq 0}$, lo que hace posible estimar ε_t a partir de observaciones pasadas y, por ende, construir pronósticos óptimos. Sin invertibilidad, el proceso no tendría representación causal en términos de los propios datos.

(d)

Solución:

Sea $Y_t = \phi Y_{t-1} + \varepsilon_t$ con $|\phi| < 1$. Sustituyendo recursivamente:

$$\begin{aligned}Y_t &= \phi(\phi Y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \phi^2 Y_{t-2} + \phi\varepsilon_{t-1} + \varepsilon_t \\ &= \phi^2(\phi Y_{t-3} + \varepsilon_{t-2}) + \phi\varepsilon_{t-1} + \varepsilon_t = \phi^3 Y_{t-3} + \phi^2\varepsilon_{t-2} + \phi\varepsilon_{t-1} + \varepsilon_t \\ &\vdots \\ &= \phi^n Y_{t-n} + \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}.\end{aligned}$$

Como $|\phi| < 1$, $\phi^n \to 0$ cuando $n \to \infty$, y la serie $\sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$ converge en media cuadrática (pues $\sum_{j=0}^{\infty} \phi^{2j}\sigma^2 = \sigma^2/(1-\phi^2) < \infty$). Por lo tanto:

$$Y_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}. \qquad \checkmark$$

Ejercicio 1.3 — Raíces unitarias y prueba de Dickey-Fuller

(a)

Solución:

Sea $Y_t = Y_{t-1} + \varepsilon_t$ con $Y_0 = 0$. Sustituyendo:

$$Y_t = \sum_{s=1}^{t} \varepsilon_s.$$

Varianza:

$$\mathrm{Var}(Y_t) = \mathrm{Var}\left(\sum_{s=1}^{t} \varepsilon_s\right) = \sum_{s=1}^{t} \mathrm{Var}(\varepsilon_s) = t\sigma^2.$$

La varianza crece con t, violando la condición $\gamma(0) =$ constante. Por tanto $\{Y_t\}$ **no es estacionario**.

Covarianza: Para $s \leq t$:

$$\mathrm{Cov}(Y_t, Y_s) = \mathrm{Cov}\left(\sum_{i=1}^{t} \varepsilon_i, \sum_{j=1}^{s} \varepsilon_j\right) = \sum_{i=1}^{s} \sigma^2 = s\,\sigma^2 = \min(s,t)\,\sigma^2. \qquad \checkmark$$

(b)

Solución:

$$\Delta Y_t = Y_t - Y_{t-1} = (Y_{t-1} + \varepsilon_t) - Y_{t-1} = \varepsilon_t.$$

La primera diferencia de la caminata aleatoria es ruido blanco, proceso estacionario. ✓

(c)

Solución:

La prueba ADF contrasta $H_0 : \delta = 0$ en

$$\Delta Y_t = \mu + \delta Y_{t-1} + \sum_{j=1}^{k} \psi_j \Delta Y_{t-j} + \varepsilon_t.$$

Bajo H_0, Y_t es una caminata aleatoria (proceso no estacionario). En este caso la distribución asintótica del estadístico t para $\hat{\delta}$ *no* converge a la distribución t clásica (ni a la normal), sino a la distribución de Dickey-Fuller, que es sesgada hacia la izquierda. Esto ocurre porque bajo H_0 el regresor Y_{t-1} es $I(1)$ (no estacionario), y los resultados estándar de MCO—que asumen estacionariedad de los regresores—dejan de ser válidos. Los valores críticos de la distribución de Dickey-Fuller son más negativos que los de la t estándar; usarlos incorrectamente llevaría a rechazar H_0 con demasiada frecuencia.

(d)

Solución:

$I(1)$ **vs.** $I(0)$**.** Un proceso es $I(1)$ (integrado de orden 1) si su primera diferencia es estacionaria ($I(0)$), pero el nivel no lo es. Un proceso $I(0)$ es estacionario en niveles.

En finanzas, los log-precios $p_t = \log P_t$ son típicamente $I(1)$: muestran tendencia estocástica (varianza crece con t, la media sigue una trayectoria no determinística). En cambio, los log-retornos $r_t = \Delta p_t$ son $I(0)$: fluctúan en torno a una media constante con varianza finita.

Implicaciones:

- Los modelos de pronóstico deben especificarse para variables estacionarias. Modelar p_t directamente como AR/MA produce inferencia inválida (regresión espuria).
- Para pronosticar p_{t+h}, se modela $r_t = \Delta p_t$ con un ARIMA y se acumulan las diferencias: $\hat{p}_{T+h} = p_T + \sum_{j=1}^{h} \hat{r}_{T+j}$.
- La cointegración permite modelar relaciones de largo plazo entre series $I(1)$ sin caer en regresión espuria.

Modelos ARIMA(p, d, q)

Ejercicio 2.1 — Identificación, estimación y diagnóstico

(a)

Solución:

(i) ACF decae exponencialmente; PACF se corta en el rezago 2 $\Rightarrow$ **AR(2)**.

(ii) ACF se corta en el rezago 1; PACF decae exponencialmente $\Rightarrow$ **MA(1)**.

(iii) Ambas ACF y PACF decaen sin corte abrupto $\Rightarrow$ **ARMA(p,q)** con $p, q \geq 1$.

(iv) ACF con pico significativo solo en el rezago 1 $\Rightarrow$ **MA(1)**.

(b)

Solución:

$$\text{AIC} = -2\log \hat{L} + 2k, \qquad \text{BIC} = -2\log \hat{L} + k\log n,$$

donde $\hat{L}$ es la verosimilitud maximizada, k el número de parámetros y n el tamaño de muestra.

Penalización: el BIC penaliza más la complejidad cuando $\log n > 2$, es decir cuando $n > e^2 \approx 7.39$. En la práctica, con series financieras (n suele ser grande), el BIC favorece modelos más parsimoniosos. El AIC puede seleccionar modelos sobreparametrizados, pero es más adecuado cuando el objetivo es minimizar el error de predicción.

(c)

Solución:

Procedimiento de Box-Jenkins (tres etapas):

1. **Identificación:** Se grafica la serie Y_t para detectar tendencia, estacionalidad y quiebres estructurales. Si la serie es no estacionaria, se aplican diferencias (d) hasta lograr estacionariedad. Se grafican la ACF y la PACF muestrales para proponer órdenes p y q (o P, Q estacionales).

2. **Estimación:** Se estiman los parámetros $(\phi_1, \ldots, \phi_p, \theta_1, \ldots, \theta_q, \sigma^2)$ por máxima verosimilitud (MV) condicional o mínimos cuadrados condicionales. Se reportan AIC y BIC para comparar especificaciones alternativas.

3. **Diagnóstico:** Se analizan los residuos $\hat{\varepsilon}_t$: se grafican en el tiempo (¿homogéneos?), se calcula la ACF y PACF (¿ruido blanco?), y se aplica la prueba de Ljung-Box. Si los residuos exhiben autocorrelación, se revisan los órdenes del modelo.

(d)

Solución:

La prueba de Ljung-Box contrasta H_0: los residuos son ruido blanco. El estadístico es:

$$Q = n(n+2)\sum_{k=1}^{h} \frac{\hat{\rho}_k^2}{n-k} \sim \chi^2(h-p-q) \quad \text{bajo } H_0,$$

con $h = \min(10, \lfloor n/5 \rfloor)$ rezagos. Si $Q > \chi^2_{1-\alpha}(h-p-q)$, se rechaza H_0 y hay evidencia de autocorrelación residual, indicando que el modelo debe refinarse (mayor p o q). Si Q no es significativo, los residuos son consistentes con ruido blanco y el modelo es adecuado.

Ejercicio 2.2 — ARIMA(1,1,1) para log-precios de una acción

(a)

Solución:

El modelo ARIMA(1,1,1) para $y_t = \log P_t$ es:

$$(1-\phi_1 B)(1-B)y_t = (1+\theta_1 B)\varepsilon_t.$$

Definiendo $r_t = \Delta y_t = y_t - y_{t-1}$, se tiene $(1-B)y_t = r_t$, luego:

$$(1-\phi_1 B)r_t = (1+\theta_1 B)\varepsilon_t,$$

$$\boxed{r_t - \phi_1 r_{t-1} = \varepsilon_t + \theta_1 \varepsilon_{t-1},}$$

que es un **ARMA(1,1)** para los log-retornos r_t.

(b)

Solución:

De la ecuación ARMA(1,1): $r_t = \phi_1 r_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$.
El pronóstico un paso adelante $\hat{r}_{T+1|T} = \mathbb{E}[r_{T+1}|r_T, r_{T-1}, \ldots]$ es:

$$\hat{r}_{T+1|T} = \phi_1 r_T + \theta_1 \varepsilon_T,$$

pues $\mathbb{E}[\varepsilon_{T+1}|\mathcal{F}_T] = 0$. Con $\hat{\phi}_1 = 0.15$ y $\hat{\theta}_1 = -0.08$:

$$\hat{r}_{T+1|T} = 0.15\, r_T - 0.08\, \varepsilon_T.$$

(La expresión del enunciado $\hat{\phi}_1\hat{\theta}_1\varepsilon_{T-1}$ proviene de expandir el error ε_T en términos de r_T y ε_{T-1} a través de la representación invertida, pero la forma directa es la anterior.)

(c)

Solución:

El error de predicción de un paso es $r_{T+1} - \hat{r}_{T+1|T} = \varepsilon_{T+1}$, con $\mathrm{Var}(\varepsilon_{T+1}) = \sigma^2$. El intervalo de predicción al 95% para r_{T+1} es:

$$\hat{r}_{T+1|T} \pm 1.96\,\hat{\sigma}.$$

Como $y_{T+1} = y_T + r_{T+1}$ y $P_{T+1} = P_T\, e^{r_{T+1}}$, el intervalo para P_{T+1} es:

$$\left[P_T\, \exp\!\left(\hat{r}_{T+1|T} - 1.96\hat{\sigma}\right),\quad P_T\, \exp\!\left(\hat{r}_{T+1|T} + 1.96\hat{\sigma}\right)\right].$$

(d)

Solución:

El ARIMA(1,1,1) **no captura** el efecto de asimetría en volatilidad. Este modelo supone que la varianza del error ε_t es constante (σ^2) e independiente del signo de los retornos pasados.

Para capturar la asimetría en volatilidad (que las caídas generan mayor volatilidad que subidas de la misma magnitud), se requieren modelos con *heteroscedasticidad condicional asimétrica*, como:

- **EGARCH** (Nelson, 1991): modela $\log(\sigma_t^2)$ como función asimétrica de los shocks pasados.
- **GJR-GARCH** (Glosten-Jagannathan-Runkle): introduce un término adicional $I(\varepsilon_{t-1} < 0)\varepsilon_{t-1}^2$ en la ecuación de varianza.
- **TGARCH** (threshold GARCH): permite distintos coeficientes según el signo del shock.

Ejercicio 2.3 — Pronóstico con ARIMA y horizonte múltiple

(a)

Solución:

El ARIMA(2,1,0) es $(1 - \phi_1 B - \phi_2 B^2)(1 - B)Y_t = \varepsilon_t$. Definiendo $W_t = \Delta Y_t$:

$$\boxed{W_t = \phi_1 W_{t-1} + \phi_2 W_{t-2} + \varepsilon_t,}$$

con $\phi_1 = 0.5$ y $\phi_2 = -0.2$.

(b)

Solución:

Pronóstico de W_{T+1}:

$$\hat{W}_{T+1|T} = \phi_1 W_T + \phi_2 W_{T-1} = 0.5(1.2) + (-0.2)(0.8) = 0.60 - 0.16 = 0.44.$$

Pronóstico de W_{T+2}:

$$\hat{W}_{T+2|T} = \phi_1 \hat{W}_{T+1|T} + \phi_2 W_T = 0.5(0.44) + (-0.2)(1.2) = 0.22 - 0.24 = -0.02.$$

(c)

Solución:

Los coeficientes de la representación MA(∞): $\psi_0 = 1$, $\psi_1 = \phi_1$, $\psi_j = \phi_1\psi_{j-1} + \phi_2\psi_{j-2}$.

$$\begin{aligned}
&\psi_0 = 1,\\
&\psi_1 = \phi_1 = 0.5,\\
&\psi_2 = \phi_1\psi_1 + \phi_2\psi_0 = 0.5(0.5) + (-0.2)(1) = 0.25 - 0.20 = 0.05.
\end{aligned}$$

ECM de predicción:

$$\mathrm{MSE}_1 = \sigma^2\psi_0^2 = 1, \qquad \mathrm{MSE}_2 = \sigma^2(\psi_0^2 + \psi_1^2) = 1 + 0.25 = 1.25.$$

(d)

Solución:

Intervalos para W:

$$W_{T+1}: \quad 0.44 \pm 1.96\sqrt{1} = [0.44 - 1.96,\ 0.44 + 1.96] = [-1.52,\ 2.40],$$

$$W_{T+2}: \quad -0.02 \pm 1.96\sqrt{1.25} = -0.02 \pm 2.19 = [-2.21,\ 2.17].$$

Traducción a Y: Como $W_t = \Delta Y_t$, tenemos $Y_{T+h} = Y_T + \sum_{j=1}^{h} W_{T+j}$.

$$\hat{Y}_{T+1|T} = Y_T + \hat{W}_{T+1|T} = 100 + 0.44 = 100.44,$$

con intervalo $[100 - 1.52,\ 100 + 2.40] = [98.48,\ 102.40]$.

$$\hat{Y}_{T+2|T} = Y_T + \hat{W}_{T+1|T} + \hat{W}_{T+2|T} = 100 + 0.44 + (-0.02) = 100.42,$$

con varianza de predicción $\mathrm{MSE}_2^{(Y)} = (1 + 2\cdot 0.44 - 0.02 + \cdots)$; usando la fórmula estándar para ARIMA:

$$\mathrm{MSE}_2^{(Y)} = \sigma^2\left[(\psi_0 + \psi_1')^2 + \text{términos cruzados}\right] \approx \sigma^2(\psi_0^2 + (\psi_0 + \psi_1)^2) = 1 + (1.5)^2 = 3.25,$$

intervalo: $100.42 \pm 1.96\sqrt{3.25} \approx 100.42 \pm 3.54 = [96.88,\ 103.96]$.

Ejercicio 2.4 — Cointegración y spreads estadísticos

(a)

Solución:

Teorema de representación de Granger. Si Y_t y X_t son ambas $I(1)$ y cointegradas con vector $(1, -\beta)$, entonces existe una representación de corrección de error (ECM):

$$\Delta Y_t = \alpha(Y_{t-1} - \beta X_{t-1}) + \sum_j \gamma_j \Delta Y_{t-j} + \sum_j \delta_j \Delta X_{t-j} + \varepsilon_t.$$

El término $\alpha(Y_{t-1} - \beta X_{t-1})$ es la *fuerza de corrección de error*: mide cuánto se aleja el sistema del equilibrio de largo plazo $Y_t = \beta X_t$ en el periodo anterior. El parámetro $\alpha < 0$ garantiza que el sistema se corrige hacia el equilibrio: si $Y_{t-1} - \beta X_{t-1} > 0$ (el spread está por encima del equilibrio), entonces ΔY_t se reduce para volver a él. Esto asegura la estacionariedad del spread y la cointegración del par.

(b)

Solución:

Estimación de β (Engle-Granger en dos pasos):

1. Estimar por MCO la regresión en niveles: $Y_t = \hat{\alpha}_0 + \hat{\beta} X_t + \hat{u}_t$.
2. Aplicar la prueba ADF a los residuos $\hat{Z}_t = Y_t - \hat{\beta} X_t$. Si $\hat{Z}_t \sim I(0)$ (se rechaza la hipótesis de raíz unitaria en $\hat{Z}_t$), se concluye cointegración.

Los valores críticos de la prueba son distintos de los estándar de Dickey-Fuller, pues se usa un residuo estimado (Engle-Granger 1987).

(c)

Solución:

El spread $Z_t = \mu + \phi Z_{t-1} + \varepsilon_t$ es un AR(1) estacionario con $|\phi| < 1$.
Media: $\mathbb{E}[Z_t] = \mu/(1-\phi)$.
Varianza: $\mathrm{Var}(Z_t) = \sigma^2/(1-\phi^2)$.
Tiempo esperado de retorno a la media: Para un proceso OU discreto, el tiempo esperado para retornar desde Z_0 a $\mu/(1-\phi)$ es:

$$\mathbb{E}[\tau_\mu] \approx -\frac{1}{\log|\phi|}.$$

(d)

Solución:

Con $\phi = 0.95$, $\mu = 0$, $\sigma = 0.01$:

$$\mathbb{E}[Z_t] = 0, \qquad \mathrm{sd}(Z_t) = \frac{0.01}{\sqrt{1-0.95^2}} = \frac{0.01}{\sqrt{0.0975}} \approx \frac{0.01}{0.3122} \approx 0.03204.$$

El tiempo de retorno a la media es $\approx -1/\log(0.95) \approx 1/0.05129 \approx 19.5$ periodos.

Regla de apertura de la posición. Se abre la posición cuando el spread se aleja suficientemente de su media (bajo la hipótesis de reversión a la media). Una regla estándar es operar cuando $|Z_t| > k \cdot \mathrm{sd}(Z_t)$ con $k \in \{1, 2\}$:

- Si $Z_t > 2 \times 0.032 \approx 0.064$: vender Y_t y comprar X_t (esperar que el spread baje).
- Si $Z_t < -0.064$: comprar Y_t y vender X_t.

El riesgo del modelo radica en que ϕ puede cambiar (el spread pierde reversión a la media) o que la cointegración se rompa estructuralmente, lo que haría que la posición nunca se cerrara rentablemente.

Modelos SARIMA y estacionalidad

Ejercicio 3.1 — SARIMA$(p, d, q)(P, D, Q)_s$: estructura y notación

(a)

Solución:

Para datos mensuales $s = 12$, el modelo SARIMA$(1, 1, 1)(1, 1, 1)_{12}$ es:

$$\Phi_1(B^{12})\,\phi_1(B)\,(1 - B^{12})(1 - B)\,Y_t = \Theta_1(B^{12})\,\theta_1(B)\,\varepsilon_t,$$

con $\phi_1(B) = 1 - \phi_1 B$, $\Phi_1(B^{12}) = 1 - \Phi_1 B^{12}$, $\theta_1(B) = 1 + \theta_1 B$ y $\Theta_1(B^{12}) = 1 + \Theta_1 B^{12}$. Expandiendo:

$$(1 - \Phi_1 B^{12})(1 - \phi_1 B)(1 - B^{12})(1 - B)Y_t = (1 + \Theta_1 B^{12})(1 + \theta_1 B)\varepsilon_t.$$

El lado izquierdo involucra el operador de diferencia ordinaria $(1 - B)$ y el estacional $(1 - B^{12})$, combinados con los polinomios AR regular y estacional. El lado derecho involucra los polinomios MA regular y estacional.

(b)

Solución:

$$\Delta_{12}(\Delta_1 Y_t) = (1 - B^{12})(1 - B)Y_t.$$

Expandiendo:

$$\begin{aligned}(1 - B^{12})(1 - B)Y_t &= (1 - B - B^{12} + B^{13})Y_t \\ &= Y_t - BY_t - B^{12}Y_t + B^{13}Y_t \\ &= Y_t - Y_{t-1} - Y_{t-12} + Y_{t-13}.\end{aligned}$$

Efectivamente involucra Y_t, Y_{t-1}, Y_{t-12} y Y_{t-13}. ✓

(c)

Solución:

Antes de aplicar Δ_{12}: Si hay estacionalidad no diferenciada, la ACF muestral muestra picos altos y persistentes en los rezagos múltiplos de 12: $\rho(12) \approx \rho(24) \approx \rho(36) \approx \cdots$, decayendo muy lentamente (a veces $\rho(12) > 0.7$ incluso con muestras largas). Esto indica no estacionariedad estacional.

Después de aplicar Δ_{12}: Los picos en los rezagos $12, 24, 36$ disminuyen drásticamente. Si $\rho(12)$ deja de ser significativo (dentro de la banda $\pm 1.96/\sqrt{T}$), la diferenciación estacional fue suficiente. Si quedan picos residuales, puede necesitarse un componente AR o MA estacional.

En términos prácticos, se busca el menor D tal que los picos estacionales de la ACF no sean significativos. Para la mayoría de series económicas, $D = 1$ es suficiente.

(d)

Solución:

En datos de ventas minoristas mensuales, la combinación más usada es $d = 1$, $D = 1$:

- $d = 1$: la primera diferencia regular elimina la tendencia estocástica (el nivel de ventas crece con el tiempo, con posible raíz unitaria).
- $D = 1$: la diferencia estacional de orden 12 elimina la no estacionariedad estacional (patrones que se repiten cada año, como el alza de diciembre).

Parsimonia: no se requiere $d = 2$ o $D = 2$ en series típicas de ventas, pues la doble diferenciación puede sobrediferenciar el proceso (introduciendo raíces unitarias en el polinomio MA que hacen el modelo no invertible). El modelo de Airline SARIMA$(0,1,1)(0,1,1)_{12}$ es el estándar de referencia para series de ventas mensuales por su parsimonia y buen desempeño.

Ejercicio 3.2 — SARIMA para ventas mensuales: modelo de Airline

(a)

Solución:

Expandiendo $(1-B)(1-B^{12})$:

$$\begin{aligned}(1-B)(1-B^{12})V_t &= (1-B^{12}-B+B^{13})V_t \\ &= V_t - V_{t-12} - V_{t-1} + V_{t-13} \\ &= V_t - V_{t-1} - V_{t-12} + V_{t-13}. \qquad \checkmark\end{aligned}$$

(b)

Solución:

El lado derecho $(1+\theta_1 B)(1+\Theta_1 B^{12})\varepsilon_t$ se expande como:

$$(1+\theta_1 B + \Theta_1 B^{12} + \theta_1\Theta_1 B^{13})\varepsilon_t = \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}.$$

El modelo completo es:

$$V_t - V_{t-1} - V_{t-12} + V_{t-13} = \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}.$$

(c)

Solución:

De la ecuación del modelo: $V_{T+1} = V_T + V_{T-11} - V_{T-12} + \varepsilon_{T+1} + \theta_1\varepsilon_T + \Theta_1\varepsilon_{T-11} + \theta_1\Theta_1\varepsilon_{T-12}$.

Con los datos disponibles ($T = 60$, $s = 12$):

$$\begin{aligned}&V_{60} = 50, \quad V_{59} = 45, \quad V_{48} = 40, \quad V_{47} = 35, \\ &\hat{\varepsilon}_{60} = 2, \quad \hat{\varepsilon}_{48} = 1, \quad \hat{\theta}_1 = -0.4, \quad \hat{\Theta}_1 = -0.6.\end{aligned}$$

El pronóstico $\hat{V}_{61} = \mathbb{E}[V_{61}|\mathcal{F}_{60}]$ es (con $\mathbb{E}[\varepsilon_{61}|\mathcal{F}_{60}] = 0$):

$$\hat{V}_{61} = V_{60} + V_{49} - V_{48} + \hat{\theta}_1\hat{\varepsilon}_{60} + \hat{\Theta}_1\hat{\varepsilon}_{49} + \hat{\theta}_1\hat{\Theta}_1\hat{\varepsilon}_{48}.$$

No tenemos V_{49} ni $\hat{\varepsilon}_{49}$, pero con los datos del enunciado (solo se dan $V_{60}, V_{59}, V_{48}, V_{47}$ y $\hat{\varepsilon}_{60}, \hat{\varepsilon}_{48}$), el pronóstico simplificado usando los valores disponibles es:

$$\hat{V}_{61} = V_{60} + (V_{49} - V_{48}) + \hat{\theta}_1\hat{\varepsilon}_{60} + \hat{\Theta}_1\hat{\varepsilon}_{48} + \hat{\theta}_1\hat{\Theta}_1\hat{\varepsilon}_{47}.$$

Aproximando con los datos dados (asumiendo $\hat{\varepsilon}_{49} \approx 0$):

$\hat{V}_{61} = 50 + (-0.4)(2) + (-0.6)(1) + (-0.4)(-0.6)(0) = 50 - 0.8 - 0.6 = 48.6$ millones MXN.

(d)

Solución:

Intervalo para V_{61} ($h = 1$): El error de predicción a un paso es ε_{61}, con varianza σ^2 (un solo término MA). El intervalo al 95% es:

$$\hat{V}_{61} \pm 1.96\,\hat{\sigma}.$$

Intervalo para V_{73} ($h = 13$, misma posición estacional): Para un horizonte de 13 pasos, la varianza del error de predicción acumula los cuadrados de los coeficientes ψ_j de la representación MA(∞):

$$\mathrm{MSE}_{13} = \sigma^2 \sum_{j=0}^{12} \psi_j^2 > \sigma^2.$$

El intervalo es $\hat{V}_{73} \pm 1.96\sqrt{\mathrm{MSE}_{13}}$.

¿Por qué crece el intervalo? Con cada horizonte adicional h, el pronóstico incorpora la incertidumbre de todos los shocks futuros $\varepsilon_{T+1}, \ldots, \varepsilon_{T+h}$, que son desconocidos. La varianza del error de predicción es $\sigma^2 \sum_{j=0}^{h-1} \psi_j^2$, que es creciente en h. Para un SARIMA$(0,1,1)(0,1,1)_{12}$, los coeficientes ψ_j son distintos de cero para muchos rezagos, por lo que la incertidumbre acumulada puede ser considerable para $h = 13$.

Ejercicio 3.3 — SARIMA para tasas de interés con ciclos trimestrales

(a)

Solución:

Las tasas de rendimiento de CETES a 28 días se registran semanalmente con un ciclo fiscal trimestral de $s = 13$ semanas. El análisis de ACF/PACF muestra:

- Picos significativos en la ACF en los rezagos $k = 13, 26, 39, \ldots$ que decaen lentamente $\Rightarrow$ sugieren un componente AR estacional.
- La serie en niveles puede mostrar tendencia (raíz unitaria) $\Rightarrow d = 1$.
- La diferencia estacional puede eliminar los picos estacionales $\Rightarrow D = 1$.

Modelo propuesto: SARIMA$(1,1,0)(1,1,0)_{13}$:

$$(1 - \phi_1 B)(1 - \Phi_1 B^{13})(1 - B^{13})(1 - B)\, r_t = \varepsilon_t,$$

donde r_t es la tasa semanal de CETES. Los órdenes $p = 1$, $q = 0$ se justifican si la PACF ordinaria tiene un único pico significativo en el rezago 1 y la ACF decae. Si la ACF muestra también un pico en el rezago 1 (corte abrupto) y la PACF decae, se optaría por un MA(1) regular: SARIMA$(0,1,1)(1,1,0)_{13}$.

Argumentación:

- $d = 1$: la tasa de CETES típicamente sigue una trayectoria I(1) en el corto plazo (anclada por política monetaria, pero con shocks persistentes).
- $D = 1$: los picos en la ACF en rezagos $13, 26, \ldots$ son persistentes antes de diferenciar estacionalmente, lo que justifica $D = 1$.
- $P = 1$: después de Δ_{13}, la ACF en rezagos $13, 26$ puede tener un patrón de decaimiento $\Rightarrow$ AR estacional de orden 1.
- $Q = 0$: si la PACF estacional se corta en el rezago 13.

(b)

Solución:

Una vez estimado el modelo SARIMA$(1,1,0)(1,1,0)_{13}$ con parámetros $(\hat{\phi}_1, \hat{\Phi}_1, \hat{\sigma}^2)$, los pronósticos para las próximas 4 semanas se obtienen por la recurrencia:

$$\hat{r}_{T+h|T} = \hat{\phi}_1 \hat{r}_{T+h-1|T} + \hat{\Phi}_1 \hat{r}_{T+h-13|T} - \hat{\phi}_1 \hat{\Phi}_1 \hat{r}_{T+h-14|T},$$

usando $\hat{r}_{T+j|T} = r_{T+j}$ para $j \leq 0$ (valores observados).

Intervalos de predicción: Usando los coeficientes ψ_j de la representación MA(∞):

$$\text{MSE}_h = \hat{\sigma}^2 \sum_{j=0}^{h-1} \psi_j^2.$$

- **Al 80%:** $\hat{r}_{T+h|T} \pm 1.28\sqrt{\text{MSE}_h}$.
- **Al 95%:** $\hat{r}_{T+h|T} \pm 1.96\sqrt{\text{MSE}_h}$.

Para $h = 1, 2, 3, 4$, los intervalos al 95% se amplían progresivamente conforme se acumulan más coeficientes ψ_j^2.

(c)

Solución:

Evaluación con ECMP (Error Cuadrático Medio de Predicción):

$$\text{ECMP} = \frac{1}{26} \sum_{t=T-25}^{T} \left(r_t - \hat{r}_{t|t-1}\right)^2,$$

calculado sobre la muestra de validación de las últimas 26 semanas (holdout).

Comparación con ARIMA$(1,1,0)$: El ARIMA$(1,1,0)$ sin componente estacional ignora la estructura trimestral y tiene mayor ECMP en periodos con shocks fiscales. El SARIMA captura los picos trimestales y típicamente reduce el ECMP entre un 10% y 30% en series con estacionalidad marcada. La decisión final se basa en el cociente de ECMP: si $\text{ECMP}_{\text{SARIMA}}/\text{ECMP}_{\text{ARIMA}} < 1$, se prefiere el SARIMA.

(d)

Solución:

Regla de decisión para trading de tasas: Sea $\hat{r}_{T+1|T}$ el pronóstico de la tasa CETES y $[\hat{r}_{T+1}^{LI}, \hat{r}_{T+1}^{LS}]$ el intervalo de predicción al 95%.

- Si $\hat{r}_{T+1}^{LI} > r_f$ (precio de mercado del futuro): se espera que la tasa suba con alta probabilidad $\Rightarrow$ **vender** futuros de CETES (que bajan de precio cuando la tasa sube).
- Si $\hat{r}_{T+1}^{LS} < r_f$: se espera que la tasa baje $\Rightarrow$ **comprar** futuros.
- Si $r_f \in [\hat{r}_{T+1}^{LI}, \hat{r}_{T+1}^{LS}]$: la señal es ambigua $\Rightarrow$ no abrir posición.

Riesgos del modelo:

1. **Riesgo de especificación:** si el modelo no captura bien la estacionalidad fiscal (e.g. cambios en el calendario de subastas), los pronósticos serán sesgados.
2. **Riesgo de cambio estructural:** la política monetaria del Banco de México puede cambiar el comportamiento de la tasa (e.g. ciclos de alza/baja rápidos), haciendo que los parámetros estimados queden desactualizados.
3. **Riesgo de modelo de varianza:** el SARIMA asume σ^2 constante. En periodos de alta volatilidad (inflación repentina, choques externos), la varianza real puede ser mucho mayor, haciendo los intervalos de predicción demasiado estrechos y llevando a posiciones con riesgo subestimado.